

Pierwszy pozytywny wynik w serii: deterministyczny override podnosi detekcję flag bitowych z 0% do 95%

Test Kierunku B (hybrydowy override klasyczny) na Claude Sonnet 5 — modelu, który w KAŻDYM z 4 dotychczasowych wariantów promptu (zero-shot, few-shot, entropy-analysis, context-fix) notował twardy sufit 0% na sygnałach dyskretnych (flagi bitowe).

TEZA


Jeśli LLM błędnie zinterpretuje bajt pakujący kilka niezależnych flag bitowych jako pojedynczy skalar, da się to wykryć DETERMINISTYCZNIE — z obserwowanych wzorców zmian wartości w czasie (nie z ground truth, bez uczenia modelu) — i programowo skorygować przed oceną.

POTWIERDZONA

KONTRAST Z 4 POPRZEDNIMI PRÓBAMI

- Zero-shot (baseline): 0,0% na flagach bitowych
- Few-shot (przykłady w promptcie): 0,0% — model zignorował przykład
- Entropy-analysis (wymuszona procedura per-bajt): 0,0% — model zignorował procedurę
- Context-fix (czysty bufor per-CAN-ID): 0,0% — bez zmiany
- Hybrydowy override (ten test): 90,9–97,0% — pierwsza skuteczna interwencja

WYNIK — DETEKCJA PER SYGNAŁ, CLAUDE SONNET 5 (N=100)



ŚREDNIA DETEKCJA (10 SYGNAŁÓW): 50,0% → 96,7%

Wszystkie 5 sygnałów dyskretnych: $F1 = 0 \rightarrow 1,000$. Wszystkie 5 sygnałów ciągłych bez zmiany detekcji (97,0–100%) – override nie ingeruje w sygnały, które LLM już rozpoznaje poprawnie.

Mechanizm: deterministyczna klasyfikacja bajtu na podstawie wielkości skoków wartości w kolejnych próbkach w czasie (nie na podstawie ground truth – uczciwa, samodzielna heurystyka). Jeśli LLM zaproponuje pojedynczy skalar dla bajtu wyglądającego jak niezależne flagi, kod programowo zastępuje go zestawem reguł per-bit przed oceną.

⚠ OGRANICZENIE ZNALEZIONE I NAPRAWIONE ● POTWIERDZONE NAPRAWIONE**FAŁSZYWE TRAFIENIA NA SYGNAŁACH CIĄGŁYCH – USUNIĘTE**

Pierwsza wersja klasyfikatora uruchamiała się (błędnie) w 29/34 próbach na CAN ID 0x100 (RPM/CoolantTemp/Throttle – same sygnały ciągłe, zero flag bitowych), lekko degradując RMSE Throttle (39,4 → 43,2) bez wpływu na detection rate.

Przyczyna: heurystyka v1 wymagała tylko JEDNEGO bitu niezależnie przełączającego stan – przy rzadkim próbkowaniu (odstępy rzędu dziesiątek sekund) zwykły powolny random-walk (np. Throttle) akumuluje duże skoki wartości, mylone z przełączeniem bitu.

Poprawka (v2): dodano wymóg, by liczba niezależnie przełączających się bitów mieściła się w przedziale [2,6] – prawdziwe flagi używają PODZBIORU bitów bajtu (reszta zarezerwowana/stała), a skalar wykorzystujący niemal cały bajt (7-8 bitów) niemal na pewno nie jest polem flag.

Wynik po poprawce (ten sam test, N=100): fałszywe trafienia na 0x100 spadły z 29/34 do **1/34**, RMSE Throttle bez zmian (37,4 → 37,4), średnia detekcja wzrosła dalej do 96,7% (z 94,0% w pierwszej, niedoskonałej wersji override'u).