

Który model najlepiej dekoduje magistralę CAN?

Claude Sonnet 5, GPT-5.6-sol, DeepSeek-v4-pro i Gemini-3.6-flash – ten sam syntetyczny mini-DBC (10 sygnałów), ten sam sprzęt, N=100 prób na model.


#1 GPT-5.6-sol 67,9% śr. detection rate	#2 Gemini-3.6-flash 50,9% śr. detection rate	#3 Claude Sonnet 5 47,9% śr. detection rate	#4 DeepSeek-v4-pro 41,5% śr. detection rate
--	---	--	--

⚠ DWA BŁĘDY METODOLOGICZNE NAPRAWIONE W TRAKCIE SESJI

UWAGA METODOLOGICZNA

- Dopasowanie bajt/bit** – pierwsza wersja kodu porównującego dopasowywała ground truth do reguły LLM tylko po numerze bajtu, nie po konkretnym bicie. Dawało to fikcyjne wyniki dla 5 flag dzielących jeden bajt. Naprawione.
- Ucinanie odpowiedzi (maxTokens=1024)** – katastrofalnie ucinano odpowiedzi DeepSeek i Gemini (fikcyjne 0% detection rate), Claude częściowo (13/54). Zwiększone do 8192, wszystkie 4 modele przetestowane od zera.

III DETECTION RATE – ŚREDNIA PO 10 SYGNAŁACH




Śr. F1 – sygnały dyskretne, gdy wykryte

Śr. RMSE – sygnały ciągłe, gdy wykryte (niżej = lepiej)

GPT-5.6-sol 1,00

Gemini 709



DETECTION RATE PER SYGNAŁ [%]

	Claude	GPT-5.6	DeepSeek	Gemini
SteeringAngle	100,0	100,0	90,9	100,0
VehicleSpeed	100,0	100,0	90,9	100,0
RPM	100,0	100,0	85,3	100,0
CoolantTemp	100,0	100,0	41,2	94,1
Throttle	79,4	100,0	73,5	100,0
RightIndicator	0,0	36,4	6,1	3,0
Headlights	0,0	36,4	6,1	3,0
DriverDoor	0,0	36,4	6,1	3,0
Handbrake	0,0	33,3	9,1	3,0
LeftIndicator	0,0	36,4	6,1	3,0

CHARAKTERYSTYKA KAŻDEGO MODELU

- GPT-5.6-sol

Wygrywa jednoznacznie — najwyższy detection rate i perfekcyjny F1 (1,000) na wszystkich wykrytych sygnałach dyskretnych. Jedyne model konsekwentnie poprawnie rozkładający bajt na 5 osobnych flag bitowych.
- Gemini-3.6-flash

Najlepszy RMSE (709) ze wszystkich modeli, gdy poprawnie zidentyfikuje sygnał — najbardziej precyzyjne oszacowanie skali/offsetu, mimo środkowego miejsca w detection rate.
- Claude Sonnet 5

Solidny na sygnałach ciągłych (79–100%), ale we wszystkich 100 próbach konsekwentnie interpretuje bajt flag jako jedną wartość skalarną zamiast 5 bitów — spójny styl, nie błąd, niedopasowany do struktury akurat tego sygnału.
- DeepSeek-v4-pro

Najsłabszy w tym teście — model "rozumujący" o długim czasie odpowiedzi (15–60s), prawdopodobnie kosztem tokenów potrzebnych na precyzyjną odpowiedź

kończącą.

WNIOSEK

BRAK JEDNEGO UNIWERSALNEGO ZWYCIĘZCY

GPT-5.6-sol najlepszy całościowo — wygrywa obie metryki, dobry domyślny wybór. **Gemini** ma najlepszą precyzję liczbową, gdy trafi strukturę. **Claude** silny na sygnałach ciągłych, ale wymaga innego promptu dla upakowanych flag bitowych. **DeepSeek** najślabszy — prawdopodobnie koszt długiego rozumowania.

Źródło: Eksperyment 4.1, MagistrałaCAN4, N=100 na model, sesja 2026-07-27 · pełny raport: Eksperyment_4.1_Model_Comparison_Raport_20260727.md