

Czy któryś z modeli można doszkolić do lepszej detekcji?

PYTANIE WYKŁADOWCY

„Ciekawe... Hmm... Zastanawiam się, czy można by któryś z nich doszkolić do nowych funkcji detekcji.”

III, TRZY DROGI, ROSNĄCY KOSZT

- 1

Przykłady w promptcie (few-shot)

koszt: ●○○

Bez treningu. Dodanie 2–3 przykładów par (ramka → poprawna reguła) do promptu, jawnie pokazujących, że jeden bajt może zawierać kilka niezależnych flag bitowych — dokładnie słabość znaną u Claude'a. Testowalne w kilka minut, praktycznie za darmo.
- 2

Prawdziwy fine-tuning wag modelu

koszt: ●●○

Dostępność zależy od dostawcy (zestawienie niżej) — od w pełni otwartego (DeepSeek) po całkowicie zamknięty (Claude). Wymaga zebrania danych treningowych i infrastruktury do treningu/API.
- 3

Wykorzystanie już zebranych danych jako zbioru treningowego

koszt: ●●●

Harness z Eksperymentu 4.1 (N=100, znany ground truth) to gotowy zbiór ewaluacyjny/treningowy. Można wygenerować więcej przykładów tym samym generatorem, dotrenować model i ocenić dokładnie tym samym skryptem — czysty eksperyment przed/po.

📁 DOSTĘPNOŚĆ FINE-TUNINGU PER DOSTAWCA

	Claude	GPT	DeepSeek	Gemini
Wagi modelu	● zamknięte	● zamknięte	● open-weight	● zamknięte

	Claude	GPT	DeepSeek	Gemini
Fine-tuning przez API	● brak (publicznie)	● częściowy, zależny od modelu	● tak, pełna kontrola	● tak, Vertex AI, wybrane modele
Trening self-hosted	● niemożliwy	● niemożliwy	● możliwy (LoRA/pełny)	● niemożliwy
Wynik dziś (detection rate)	47,9%	67,9%	41,5%	50,9%

🏠 REKOMENDACJA

ZACZĄĆ TANIO, ESKALOWAĆ W RAZIE POTRZEBY

Zacząć od **opcji 1** (few-shot w promptcie) – to niemal darmowy test, który wprost adresuje znaną słabość Claude'a (traktowanie bajtu flag jako skalara).

Jeśli to nie wystarczy: **DeepSeek** jest najciekawszym kandydatem do prawdziwego dotrenowania – jedyny model w tej czwórce z otwartymi wagami, mimo najsłabszego wyniku w dzisiejszym teście zero-shot. To ciekawa ironia: najsłabszy dziś, ale jedyny, który realnie dałoby się samodzielnie poprawić.

Dane treningowe/ewaluacyjne (opcja 3) już praktycznie mamy – Eksperyment 4.1 to gotowy szkielet do pomiaru „przed/po” dowolnej z powyższych interwencji.