

Bootstrapped fine-tuning: ~120 zł kosztuje mało, prawie 4 doby sprzętu kosztują dużo

Bilans kosztów, korzyści i wartości edukacyjnej propozycji Eksperymentu 4.3 (destylacja klasycznego klasyfikatora w wagi LLM), przed podjęciem decyzji o realizacji.

KOSZT PIENIĘŻNY (4 MODELE × 30 POWTÓRZEŃ)

~120 zł

GPT-4.1 fine-tuning + ewaluacja API dla wszystkich modeli – pomijalny budżetowo

KOSZT CZASOWY (SPRZĘT SEKWENCYJNY)

~91 godz

~3,8 doby ciągłej pracy – jeden ESP32 + PCAN-USB, brak równoległości

KOSZTY – ROZBICIE

Model	Fine-tuning (raz)	Ewaluacja N=100	× 30 powtórzeń	Czas × 30
Claude	niemożliwy (brak API)	~\$0,31	~\$9,30 (~35 zł)	~11 godz
GPT-4.1	~\$2,14	~\$0,39	~\$13,84 (~52 zł)	~12,5 godz
DeepSeek	nieznany (Twój GPU)	~\$0,07	~\$1,98 + GPU (~7,50 zł + GPU)	~50 godz
Gemini	brak cennika Vertex AI FT	~\$0,21	~\$6,15 + ? (~23 zł + ?)	~17,5 godz

Kurs ~3,79 PLN/USD. Rozmiary tokenów policzone z realnych danych naszych raportów (nie szacunkowo). Niepewności: koszt GPU self-hosted DeepSeek i cennik Vertex AI Gemini – nieznane, nie zerowe.

Dodatkowo, jednorazowo: rozbudowa generatora syntetycznego (dni pracy inżynierskiej) + czas samego treningu (godziny dla GPT-4.1; nieznany dla DeepSeek).

OPTIMALIZACJA: WIELE ESP32 NA JEDNEJ MAGISTRALI CAN

CAN to magistrala **rozgłoszeniowa** – każdy podłączony węzeł widzi te same ramki jednocześnie. Skoro ESP32 w tej architekturze tylko nasłuchuje (nic nie nadaje z powrotem na magistralę), wiele modułów może słuchać JEDNEJ fizycznej magistrali równolegle, każdy przekazując do osobnej instancji MagistralaCAN4 (inny port, inny model) – **zero konfliktu, zero nowego kodu**, tylko dodatkowy sprzęt (ESP32+MCP2515, pojedynczo tanie).

Wariant	ESP32	Czas × 30 (wszystkie modele)	Oszczędność
Sekwencyjnie (1 ESP32)	1	~91 godz	—
Równolegle per model	4	~50 godz (wąskie gardło: DeepSeek)	~45%
+ 3× równolegle dla DeepSeek	6	~17,5 godz (wąskie gardło: Gemini)	~81%

Ograniczenia do rozważenia: limity API providera (RPM/TPM) przy równoczesnych zapytaniach – przy 4-6 równoległych strumieniach zwykle wciąż bezpiecznie poniżej typowych limitów; obciążenie elektryczne magistrali dla kilku dodatkowych węzłów nasłuchujących jest pomijalne (rzeczywiste pojazdy mają dziesiątki ECU na jednej magistrali).

ZYSKI I WARTOŚĆ DODANA

- **Model przestaje potrzebować zewnętrznej łatki.** Jeśli się uda, LLM sam internalizuje zasadę "mały, nie-monotoniczny zbiór wartości = flagi bitowe" — zamiast polegać na hybrydowym override'ie (Kierunek B) przy każdym zapytaniu w czasie działania.
- **Dane treningowe praktycznie za darmo.** Etykieciarzem jest już zwalidowany klasyczny klasyfikator (0 kosztu API) — nie trzeba płacić za drogie zapytania LLM tylko po to, żeby "odkryć" wzorzec, który już umiemy zakodować wprost.
- **Czysty test hipotezy destylacji.** Ten sam harness ewaluacyjny co Eksperyment 4.1 pozwala bezpośrednio porównać "przed" (zero-shot) i "po" (doutuczony) bez zmiany metodyki.
- **Wynik pozytywny LUB negatywny jest wartościowy.** Sukces pokazuje, że destylacja symboliczno-neuronowa działa nawet dla wąskiej, dobrze zdefiniowanej zasady; porażka pokazuje granicę tego podejścia — obie odpowiedzi nadają się do pracy.

🔗 WARTOŚĆ EDUKACYJNA

- Praktyczna ilustracja **destylacji wiedzy** (knowledge distillation) — jednej z ważniejszych technik nowoczesnego ML — w konkretnym, zrozumiałym kontekście inżynierskim, nie abstrakcyjnym.
- Łączy **klasyczne, deterministyczne podejście** z uczeniem maszynowym — pokazuje, że te dwa światy nie są konkurencyjne, tylko komplementarne (klasyfikator jako nauczyciel, nie zamiennik).
- Realne doświadczenie z **pełnym pipeline'em fine-tuningu**: przygotowanie danych, format treningowy, uruchomienie zadania, ewaluacja — rzadko dostępne w pracy inżynierskiej tego zakresu.

🕒 PYTANIA DO PRZEDYSKUTOWANIA Z WYKŁADOWCĄ

- 1 Czy budżet ~120 zł + ~4 doby sprzętu + dni pracy inżynierskiej mieści się w ramach czasowych pracy?
- 2 Czy 30 powtórzeń ewaluacji na model jest naprawdę potrzebne do wniosków, czy N=100 raz na model (redukcja z ~91h do ~3h) wystarczy jako pierwszy, tańszy test?
- 3 Czy DeepSeek (jedyny open-weight, ale nieznany koszt/czas treningu self-hosted) jest wart ryzyka na tym etapie, czy odłożyć go na później i skupić się na GPT-4.1 (przewidywalny koszt, gotowe API)?
- 4 Czy warto ograniczyć zakres do 1-2 modeli zamiast wszystkich 4, biorąc pod uwagę że czas sprzętu, nie pieniądze, jest realnym ograniczeniem?
- 5 Czy inwestycja w dodatkowe tanie moduły ESP32+MCP2515 (żeby zrównoleglić przebiegi na jednej magistrali CAN, ~91h → ~17,5h) mieści się w budżecie/zakresie pracy, czy pozostać przy jednym zestawie i akceptować dłuższy czas?

→ MOJA SUGESTIA

PILOTAŻ ZANIM PEŁNY PLAN

Zacząć od **samego GPT-4.1** — jedyne go modelu z przewidywalnym kosztem i gotowym API (bez niepewności GPU jak DeepSeek, bez brakującego cennika jak Gemini, bez blokady jak Claude).

Zamiast od razu $\times 30$ powtórzeń ($\sim 12,5h$ dla samego GPT-4.1), zrobić **jeden pełny cykl** (fine-tuning + $N=100$) — jeśli wynik jest obiecujący (model faktycznie internalizuje zasadę bez override'u), dopiero wtedy skalować do wielokrotnych powtórzeń dla wiarygodności statystycznej.

DeepSeek i Gemini zostawić jako **rozszerzenie po potwierdzeniu koncepcji** na GPT-4.1 — unika się ryzyka zainwestowania dni pracy inżynierskiej (rozbudowa generatora) w podejście, które może zawieść z powodów niezwiązanych z samym modelem.

Jeśli po pilotażu zdecydujemy się na pełny plan $\times 30$ dla wszystkich modeli — **zrównoleglić przez wiele ESP32** na tej samej magistrali (zero nowego kodu, tylko sprzęt) zamiast czekać 91h sekwencyjnie. To najtańszy sposób na odzyskanie $\sim 75\%$ czasu.