


# Sieć neuronowa kontra reguła ręczna w wykrywaniu flag bitowych

Klasyfikator „Kierunku B” miał sufit konstrukcyjny na poziomie 85% wykrywalności. Sprawdzono, czy sieć o 577 parametrach – mieszcząca się na urządzeniu brzegowym – potrafi go przełamać.

### PYTANIE BADAWCZE

Reguła odrzuca bajty zawierające 7-8 niezależnie przełączających się flag, choć ich współczynniki skokowości (0,97 / 0,84 / 0,82) przeszłyby każdy próg. Poluzowanie limitu do 8 daje 100% wykrywalności, ale precyzja spada do ~50%. **Granica jest nieliniowa** – czy klasyfikator uczony poradzi sobie tam, gdzie próg nie może?

### WYNIK – 2936 POZYCJI Z PRAWDZIWEGO MCP2515



KLUCZOWE LICZBY

POMINIĘTE FLAGI

0

z 424 · reguła pomija 52

PARAMETRÓW SIECI

577

MLP 10 → 24 → 12 → 1

CZAS UCZENIA

21,8 s

na Orange Pi Zero 3

ZYSK F1

+7,8 pp

wobec obecnej reguły

PEŁNE ZESTAWIENIE

24 zbiórki na sprzęcie, ziarna 100-105, cztery prędkości magistrali. 2936 pozycji, 424 z flagami.

| METODA                         | TP  | FP | FN | RECALL | PRECISION | F1    |
|--------------------------------|-----|----|----|--------|-----------|-------|
| reguła, limit 6 bitów (obecna) | 372 | 22 | 52 | 87,7%  | 94,4%     | 91,0% |
| reguła, limit 7 bitów          | 413 | 24 | 11 | 97,4%  | 94,5%     | 95,9% |
| sieć neuronowa (577 par.)      | 424 | 10 | 0  | 100%   | 97,7%     | 98,8% |

Sieć poprawia **obie osie naraz** — to nie jest kompromis „więcej wykryć kosztem fałszywych alarmów”. Wykrywa wszystkie flagi i jednocześnie myli się rzadziej niż którykolwiek wariant reguły.

Zaplanowana manipulacja nie zadziałała

Eksperyment 4.8 miał być **testem odporności poza punktem strojenia**: zmiana prędkości magistrali (125 → 1000 kbit/s) miała wyprowadzić regułę poza warunki, w których ją nastrojono. Liczby odebranych ramek okazały się jednak praktycznie identyczne na wszystkich prędkościach.

Przyczyna: generator wysyła ramki w **stałych odstępach czasowych**, niezależnie od prędkości magistrali, a przy 20 konfiguracjach nawet 125 kbit/s ma zapas przepustowości. Reżim próbkowania – a to on decyduje o statystykach klasyfikatora – pozostał niezmieniony.

**Hipotezy o odporności nie przetestowano.** Właściwą zmienną jest obciążenie magistrali (liczba CAN ID, okresy ramek), nie prędkość transmisji. Eksperyment dał natomiast to, czego brakowało wcześniej: moc statystyczną.

Wyniki w rozbiciu na prędkości – płaskie, zgodnie z powyższym

| BITRATE     | REGUŁA-6 F1 | REGUŁA-7 F1 | SIEĆ F1 |
|-------------|-------------|-------------|---------|
| 125 kbit/s  | 91,7%       | 95,8%       | 98,6%   |
| 250 kbit/s  | 91,2%       | 96,3%       | 99,1%   |
| 500 kbit/s  | 90,6%       | 96,3%       | 99,1%   |
| 1000 kbit/s | 90,3%       | 95,4%       | 98,6%   |

## EKSPERYMENT 4.9 – POTWIERDZENIE NA DRUGIM ZBIORZE

Test powtórzono z poprawioną zmienną: **obciążenie magistrali** (5, 10, 40, 60 CAN ID) zamiast prędkości. Manipulacja zadziałała – natężenie ruchu wzrosło ~20×. Sieć uczono przy 30 CAN ID, więc 5 i 60 leżą poza punktem uczenia.

F1 w zależności od obciążenia · 2742 pozycje, 426 flag, prawdziwy MCP2515

| METODA                | 5 ID         | 10 ID       | 40 ID        | 60 ID        | ŁĄCZNIE      | ROZSTĘP       |
|-----------------------|--------------|-------------|--------------|--------------|--------------|---------------|
| reguła, limit 6       | 89,5%        | 92,3%       | 90,6%        | 92,0%        | 91,4%        | 2,8 pp        |
| reguła, limit 7       | 97,6%        | 97,1%       | 96,6%        | 96,0%        | 96,4%        | 1,6 pp        |
| <b>sieć neuronowa</b> | <b>97,6%</b> | <b>100%</b> | <b>98,7%</b> | <b>98,0%</b> | <b>98,4%</b> | <b>2,4 pp</b> |

**Przewaga sieci potwierdzona niezależnie** na drugim, w pełni świeżym zbiorze: +2,0 pp F1 wobec najlepszego wariantu ręcznego, +7,0 pp wobec obecnego. Pominięta 1 flaga na 426.

### Hipoteza o większej odporności sieci – odrzucona

Zakładano, że reguła nastrojona w jednym punkcie pracy będzie degradować się poza nim szybciej niż sieć.

**Dane tego nie potwierdzają:** wszystkie trzy metody są bardzo stabilne przy 20-krotnej zmianie natężenia ruchu, a najstabilniejsza okazała się *reguła* z limitem 7 (rozstęp 1,6 pp wobec 2,4 pp sieci).

Przewaga sieci bierze się więc **wyłącznie z lepszej klasyfikacji**, nie z odporności – i tego uzasadnienia nie należy rozszerzać na argumenty, których pomiar nie potwierdza.

### Dlaczego dwie próby testu odporności z rzędu nie zadziałały

Mediana próbek na bajt pozostała w przedziale ~1000-2000 na wszystkich poziomach obciążenia, mimo 20-krotnej zmiany łącznego ruchu. Przyczyna jest strukturalna: w generatorze **każdy CAN ID nadaje z własnym, stałym okresem**. Dodanie węzłów zwiększa ruch łączny, ale nie zmienia reżimu próbkowania pojedynczego bajtu – a to on decyduje o statystykach klasyfikatora. Tak samo było z prędkością magistrali.

**Statystyki per-bajt są niewrażliwe na parametry poziomu magistrali.** Realny test odporności wymaga skalowania samych okresów ramek (generator tego nie udostępnia) albo ruchu z prawdziwego pojazdu.

- Sieć wdrożono do demona jako **drugi klasyfikator działający równolegle** z regułą. Trzy decyzje projektowe:
- 1. **Zero PyTorch w demonie.** Wagi w JSON (12,4 KB), inferencja to kilkanaście linii czystego Pythona. Wdrożenie nie dokłada ani jednej zależności — zamiast 1,3 GB instalacji i kilku sekund importu przy starcie. Równoważność zweryfikowana: **maksymalna różnica logitu  $2,66 \cdot 10^{-6}$ , zero rozbieżnych decyzji.**
  - 2. **Pamięć nadal ograniczona.** Histogram wartości to tablica o stałej długości 256 (~1 KB na bajt), nie rosnąca struktura — kluczowa własność oryginału zachowana.
  - 3. **Reguła pozostaje domyślna.** Sieć jest dodatkiem; werdykt zawiera oba rozstrzygnięcia, więc można je porównywać na żywo bez dwóch demonów na jednej magistrali.

Zmierzony narzut · 44 171 ramek w 60 s, 320 pozycji, Orange Pi Zero 3

| OPERACJA           | KOSZT            | CZĘSTOTLIWOŚĆ             |
|--------------------|------------------|---------------------------|
| akumulacja stanu   | 152,7 μs/ramkę   | każda ramka (11,2% czasu) |
| policzenie 10 cech | 34,8 μs/pozycję  | raz na snapshot           |
| inferencja sieci   | 282,4 μs/pozycję | raz na snapshot           |
| razem werdykt      | 317,3 μs/pozycję | raz na snapshot           |

Pełny snapshot 320 pozycji kosztuje ~0,1 s i wykonuje się raz na 30-60 s — **narzut pomijalny.**

## EKSPERYMENT 4.10 – TEST ODPORNOŚCI, KTÓRY WRESZCIE ZADZIAŁAŁ

Po dwóch nieudanych próbach ustalono właściwą zmienną: **skalowanie okresów nadawania**. Generator rozszerzono o parametr `--period-scale` (domyślnie 1,0 – ground truth pozostaje bit-w-bit identyczny, co zweryfikowano). Tym razem manipulacja zadziałała: mediana próbek na bajt zmieniła się od **7481** do **498** – zakres **15×**, przy zerze zgubionych ramek.

F1 w zależności od skali okresów · 1944 pozycje poza punktem uczenia, prawdziwy MCP2515

| METODA                | 0,25×        | 0,5×         | 1,0×         | 2×           | 4×           | ROZSTĘP       |
|-----------------------|--------------|--------------|--------------|--------------|--------------|---------------|
| reguła, limit 6       | 89,6%        | 90,4%        | 91,4%        | 88,9%        | 88,9%        | 2,5 pp        |
| reguła, limit 7       | 95,8%        | 95,8%        | 96,4%        | 95,2%        | 95,8%        | 1,2 pp        |
| <b>sieć neuronowa</b> | <b>98,6%</b> | <b>97,9%</b> | <b>98,4%</b> | <b>98,6%</b> | <b>99,3%</b> | <b>1,4 pp</b> |

\* punkt uczenia sieci i strojenia reguły. Sieć utrzymuje **100% wykrywalności na każdej skali**.

### Hipoteza o odporności – odrzucona rozstrzygająco

Wcześniejsze odrzucenia były *nierozstrzygające*, bo manipulacje nie zmieniały statystyk. Tutaj zmieniły je 15-krotnie – i mimo to wszystkie trzy metody pozostały bardzo stabilne (rozstępy 1,2-2,5 pp), a **najstabilniejsza znów okazała się reguła**.

**Przewaga sieci wynika wyłącznie z jakości klasyfikacji**, nie z odporności – i tak należy ją przedstawiać.

Bilans trzech prób testu odporności

| EKSPERYMENT | ZMIENNA                               | ZMIENIŁA STATYSTYKI? | WYNIK                 |
|-------------|---------------------------------------|----------------------|-----------------------|
| 4.8         | prędkość magistrali (125-1000 kbit/s) | nie                  | nierozstrzygający     |
| 4.9         | liczba CAN ID (5-60)                  | nie                  | nierozstrzygający     |
| <b>4.10</b> | <b>skala okresów ramek (0,25-4×</b>   | <b>tak, 15×</b>      | <b>rozstrzygający</b> |

Dwie pierwsze próby były pomyłką projektową: manipulowały parametrami **poziomu magistrali**, podczas gdy statystyki per-bajt zależą od **stosunku częstotliwości próbkowania do dynamiki sygnału**.

## SPRÓSTOWANIE WCZEŚNIEJSZEGO WNIOSKU

### „Jednolinijkowa zmiana parametru bije sieć neuronową” – wniosek obalony

Na wcześniejszym teście obejmującym **132 pozycje** reguła z limitem 7 wypadła lepiej niż sieć (F1 95,0% wobec 93,0%) i taki wniosek zapisano. Różnica opierała się jednak na **dwóch pozycjach** – czyli na szumie.

Przy próbie 22× większej kierunek jest odwrotny i jednoznaczny: 98,8% wobec 95,9%. Wniosek metodologiczny na przyszłość: przy 20 pozytywach w zbiorze testowym **różnice rzędu kilku punktów procentowych nie są interpretowalne**.

1. **Dane uczące z trybu `--dump-json` mają inny rozkład niż żywa magistrala.** Ta sama reguła daje na nich 42,6% wykrywalności zamiast 85%. Symulacja skokowa czasu (50 ms/próbkę) i zbyt mało próbek zmieniają statystyki przełączeń. Sieć nauczona na takich danych wyglądałaby dobrze na walidacji i rozsypała się przy wdrożeniu. Rozwiązanie: dane z wirtualnych magistral `vcan` z realnym taktowaniem — rozkład zgodny co do 0,1 pp.
2. **Kolektor uruchomiony przez `nohup ... &` po SSH kończy się natychmiast** (proces nie żyje po 4 s mimo zadanych 20) i zapisuje *poprawnie* wyglądający plik z zerem ramek. Ten sam kolektor na pierwszym planie odbiera komplet danych. Błąd był groźny, bo nie wyglądał na błąd — wychwyciło go dopiero to, że wszystkie cztery prędkości dały identyczne zero, co fizycznie nie miało sensu.

## WNIOSKI I REKOMENDACJE

---

**1. Sieć przełamuje sufit konstrukcyjny reguły** — 100% wykrywalności przy ~97% precyzji, modelem o 577 parametrach uczonym w 21,8 s na urządzeniu brzegowym. Przewaga potwierdzona na **trzech niezależnych zbiorach sprzętowych** (~7600 pozycji) i utrzymuje się na każdym testowanym punkcie pracy.

**1b. Metoda nie wymaga strojenia pod punkt pracy.** Trzy manipulacje — prędkość magistrali (8×), liczba węzłów (12×), gęstość próbkowania (15×) — zmieniły F1 wszystkich metod o najwyżej 2,5 pp. Raz nastrojony klasyfikator działa w szerokim zakresie warunków bez rekalkibracji.

**2. Jeśli sieć jest niepożądana**, sama zmiana limitu bitów z 6 na 7 daje ~+5 pp F1 przy zerowym koszcie obliczeniowym — jedna linia w trzech plikach. **Potwierdzone na dwóch niezależnych korpusach** (+5,0 pp i +4,9 pp, rozbieżność 0,1 pp).

**3. Mocniejszy sprzęt nie jest potrzebny** — ani do uczenia, ani do inferencji. Gdyby kiedykolwiek był, wąskim gardłem byłby VRAM karty graficznej (fine-tuning LLM albo model lokalny), a nie liczba rdzeni CPU ani RAM.

---

**Zastrzeżenie:** cały ruch jest syntetyczny, z generatora Eksperymentu 4.3. Test na innych ziarnach ogranicza ryzyko zapamiętywania, ale inne ziarno to wciąż ten sam generator. Wynik jest mocną przesłanką, **nie dowodem** na prawdziwej magistrali samochodowej.

Protokół: uczenie ziarna 1-24 (`vcan`, 4300 pozycji) · walidacja ziarna 25-30 (wyłącznie do wyboru epoki) · test ziarna 100-105 na prawdziwym MCP2515. Raport źródłowy: `Eksperyment_4.7-4.10_Siec_Neuronowa_vs_Regula_20260815.md`